

Večmodalna poravnava medicinskih slik

Vpliv izbire metode interpolacije

Saša Nikolić
UP FAMNIT
Koper, Slovenija
sasa.nikolic@student.upr.si

Povzetek—S poravnavo slik ugotavljamo geometrijsko relacijo med objekti, ki so prisotni na primerjanih slikah. V sodobnih medicinskih aplikacijah lahko z njo omogočimo enotno in hkratno uporabo več slik in iz njih razberemo različne informacije o slikani anatomiji. Z raziskovanjem področja poravnave medicinskih slik prispevamo k odkrivanju in boljšem razumevanju bolezenskih stanj, načrtovanju kirurških posegov in terapij za zdravljenje opaženega obolenja. Skrbno preučevanje poravnanih medicinskih slik lahko vodi k boljši učinkovitosti zdravljenja ter splošnemu napredku v zdravstvu. Poravnava je potrebna zaradi neskladij med dobljenimi slikami, ki so tipično zajete neodvisno, vsebujeta pa isti objekt. Razlog za to je lahko posledica različne lege pacienta, delovanje patoloških sprememb in organov, spremembe pa so pogosto lokalne narave. V tem članku je predstavljena osnovna ideja poravnave medicinskih slik, v drugem delu pa opis in dejanska implementacija metode interpolacije.


Ključne besede—poravnava slik; medicina; mere podobnosti; Matlab; interpolacija

I. UVOD

Obdelavo slik je mogoče opredeliti kot manipulacijo in analizo informacij, vsebovanih v slikah. Definicija je sigurno zelo obsežna in vključuje tako naravne, kot »umetno« pridobljene slike, s pomočjo raznih naprav. Veliko število aplikacij zgornje definicije je mogoče najti v medicinski znanosti. Z uporabo ene ali več slik pacienta, so mogoči naslednji postopki:

- **Vizualizacija:** npr. preden lahko naredimo vizualizacijo objekta v 3D, je pogosto potrebno pridobiti informacije o objektu iz dvo-dimenzionalne slike (Slika 1).
- **Računalniško podprta diagnoza:** npr. v bolj razvitih državah je skupno, da ženske v določeni starosti opravijo radiografski test, za odkrivanje raka na dojki. V praksi, je pridobljenih slik s tem preveč, zato si pomagamo z avtomatičnim računalniškim procesiranjem slik.
- **Segmentacija slik:** delitev slike v smiselne dele oz. strukture. Npr. razdelitev slike možganov v strukture, kot so belo možgansko tkivo, sivo možgansko tkivo, cerebrospinalna tekočina, kosti, maščoba, koža. Segmentacija je uporabna za boljšo vizualizacijo in spremljanje razvoja bolezni.

- **Poravnava slike** (ujemanje slike): natančna poravnava dveh ali več slik istega pacienta, ki je uporabna, če želimo informacijo iz teh slik predstaviti v novi sliki.




Slika 1: Primer pridobivanja informacij iz obdelave slik. Slika v 3D na levi je bila pridobljena iz 2D slike na desni.

Medicinske slike predstavljajo stanje ali dogajanje v telesu in s tem občutno pripomorejo k lažjemu razumevanju in odkrivanju raznih obolenj ali poškodb. Z njimi tudi je tudi lažje ovrednotiti zdravljenje in morebitne potrebne zdravstvene (kirurške) posege. Zelo pogosto obstaja potreba po uporabi več slik, za boljšo in lažjo predstavo o slikani anatomiji. Zaradi zajemanja slik ob drugem času, različnih napak, motenj in pod različnimi pogoji, pride pogosto do večjih razlik med slikami. Toda na vseh dobljenih slikah je skupen določen objekt, katerega želimo zdravstveno preveriti in ovrednotiti. Zato je potrebno slike geometrijsko uskladiti in jih slikovno poravnati.

Registracija ali poravnava slik je postopek iskanja optimalne geometrijske soodvisnosti dveh ali več slik, z namenom pridobiti medicinsko pomembne informacije o stanju in dogajanju v telesu [1]. S tem postopkom pridobljene informacije iznatno povečajo možnost pravilnega diagnosticiranja in zdravljenja obolelega bolnika, hkrati pa splošnega razumevanja dogajanja v telesu ter pripomore k boljši natančnosti in preglednosti raziskav.

Rezultat poravnave je geometrijska transformacija ene ali več slik. Zaradi referenciranja v prihodnje, jo poimenujemo T. S transformacijo dosežemo preslikavo poravnane slike v prostor druge slike, t.i. referenčne slike, tako da se isti objekti (v tem primeru anatomske strukture) povsod nahajajo na enakem mestu oz. da ima vsaka slikovna točka enako lego. S tem postopkom

pridobimo tako sliki, za enotno obravnavo, kot tudi informacijo o medsebojni soodvisnosti, ki je lahko pomembna za izločanje medicinsko pomembne slikovne vsebine.



Slika 2: Primer poravnave dveh slik, A je referenčna slika, B pa je poravnavana slika, rezultat B' je poravnana slika.

II. POSTOPKI PORAVNAVE SLIK

Pri medicinskih slikah se velikokrat srečujemo z problemom, ko so slike zajete z različnimi slikovnimi postopki. Takrat govorimo o večmodalni poravnavi slik, v nasprotnem primeru pa je poravnava enomodalna. Obe možnosti se med seboj razlikujeta glede na pričakovano svetlostno odvisnost med slikama. Pri enomodalni je ta linearna, večmodalna svetlostna odvisnost pa se po navadi ugotavlja statistično, njene zakonitosti pa po navadi vnaprej niso znane. Od dejanskih lastnosti slikane anatomije je odvisno, kako detaljno bomo iskali geometrijsko soodvisnost med slikami. V tem smislu poznamo togo in netogo (elastično) poravnavo. Toga poravnava omogoča ugotavljanje medsebojne lege slik - iskanje medsebojnega premika in zasuka slik. Večinoma pa se v medicini ukvarjamo z netogo poravnavo, saj v praksi vedno prihaja do nekakšnih deformacij, kot npr. zaradi delovanja organov ali elastičnosti tkiv. Pri netogi poravnavi, torej, iščemo vse lokalne razlike med slikami.


Postopke poravnave slik lahko na splošno razdelimo v tri skupine, glede na njihovo uporabo. Z *analizo slikovne informacije* lahko ugotavljamo spremembe, ki so se zgodile v določenem časovnem obdobju in združujemo informacijsko vsebino več slik. Ta pride izredno prav pri večmodalni poravnavi, saj pri tem dobimo komplementarno informacijo o slikani anatomiji, ki je potrebna za lažjo vizualizacijo in obravnavo. Druga skupina je *analiza geometrijske informacije*. Z njo lahko ugotavljamo lego pacienta, patološke spremembe in geometrijske razlike, ki so pogosto posledica delovanja organov. *Segmentacija slik* pa deluje na osnovi poravnave slike z določenim modelom, ki vsebuje podatke o segmentaciji. Za poravnano sliko postanejo v poravnanim stanju veljavni tudi vsi segmentacijski podatki podela, kot npr. označene pomembne anatomske točke, krivulje in površine.

A. Analiza slikovne odvisnosti

Združevanje informacijske vsebine več slik in analiziranje razlik med njimi je mogoče z analizo odvisnosti slikovne informacije. Najpogosteje iščemo razlike med slikami, ki so enake modalnosti (zajete z enakim slikovnim postopkom). V tem primeru nas zanimajo predvsem časovne spremembe, ki se dogajajo npr. ob poteku bolezni oz. zdravljenja. Z razlikami lahko tudi enostavno opazujemo delovanje organov, saj je mogoče zaznati že zelo majhne razlike med slikami. Te so lahko posledica šibkih lokalnih pojavov, ki jih z običajnim primerjanjem slik ni mogoče opaziti.

Na osnovi analize slikovne soodvisnosti lahko združujemo informacijsko vrednost vsebine le-teh. Uporablja se predvsem

pri večmodalni poravnavi (pri čemer je slika zajeta z različnimi postopki). Informacijo o anatomiji, pridobljeno z magnetno resonančnim slikanjem (MRI) ali računalniško tomografijo (CT) lahko s tem postopkom združimo z informacijo o aktivnosti telesa, ki jo dobimo z pozitronsko emisijsko tomografijo. Ker tako pridobimo novo informacijo o medsebojni odvisnosti slikovnih informacij, s tem omogočimo nove vpoglede v telo.




Slika 3: Primer združevanja dveh različnih slik možganov. Levi zgornji del in desni spodnji del sta del prve slike, ostala dva pa del druge slike. Uporabniku s tem omogočimo ogled informacij dveh slik hkrati.

B. Analiza geometrijske informacije

Z analizo rezultata poravnave slik (transformacij) lahko ugotavljamo geometrijske spremembe. Zelo tipičen primer je ugotavljanje delovanja organov, pri čemer lahko opazujemo njihovo gibanje. Do geometrijskih sprememb lahko pride tudi zaradi medicinskih posegov, patologij, elastičnosti tkiv v telesu ter različne lege pacienta med slikanjem.

C. Segmentacija slik

Segmentacija slik poteka s poravnavo obravnavane slike in modela anatomije. Model anatomije je najpogostejše slika tipične anatomije, ki ima slikovni informacijski dodatek še podatke o njeni segmentaciji, npr. robove pomembnih struktur, značilne anatomske točke, področja tkiv, ki so bolj pomembna in podobna. Ko poravnavamo sliko z modelom, dosežemo, da se anatomske strukture modela prilegajo strukturam na obravnavani sliki. Ker poznamo podatke o segmentih modela, tako pridobimo tudi segmentirano sliko.



Slika 4: Primer segmentacije slike možganov. Možgani na levi strani so segmentirani v 6 segmentov (različni odtenki sive barve).

III. VEČMODALNA PORAVNAVA SLIK

Različne metode zajemanja slik temeljijo na meritvah različnih lastnosti tkiv in pojavov, zato vsaka metoda predstavlja svojo modalnost, kar z drugimi besedami predstavlja način opisa slikanega telesa. S funkcionalnimi slikovnimi tehnikami pridobimo informacijo o presnovi, s anatomskimi slikovnimi tehnikami pa informacijo o zgradbi telesa. Med funkcionalne tehnike spadajo SPECT (fotonska emisijska računalniška tomografija), PET (pozitronska emisijska tomografija), fMRI (funkcionalna magnetna resonanca), itd. Med anatomske tehnike pa sodijo ljudem bolj znane tehnike, kot so RTG (rentgensko slikanje), CT (računalniška tomografija), MRI (magnetna resonanca), US (ultrazvok), MRA (magnetno resonančna angiografija), itd. Omeniti velja, da sta najbolj poznani tehniki MRI in CT trodimenzionalni (3D).

Kot že rečeno, so večmodalne slike take slike, ki so zajete z različnimi postopki in so strukturno drugačnega tipa. Npr. pari večmodalnih slik, ki jih primerjamo, so lahko:

- MRI – CT
- MRI – PET/SPECT
- Strukturirani MRI – funkcionalni MRI

Analiza slikovne odvisnosti zahteva ustrezno geometrijsko poravnavo slik za primerjavo. Tridimenzionalna poravnava večmodalnih medicinskih slik je težka, saj temelji na specifičnih lastnosti posamezne slike, kompleksnosti objektov v njej ter zaradi velikega števila metod zajemanja medicinskih slik. Medtem, ko natančnost tehnik poravnavanja, ki delujejo na osnovi ujemanja anatomskega objekta ni dobra zaradi napak v segmentaciji, tehnike, ki bazirajo na samih vokslih vzamejo v poštev prav vse voksle slike, zato take tehnike ne potrebujejo segmentacije.


Najpogostejši postopek poravnave večmodalnih slik je z uporabo medsebojne informacije kot mere podobnosti med slikama in parametričnih modelov transformacij, ki s pomočjo mreže kontrolnih točk modelirajo lokalne deformacije slik. Zaradi ocenjevanja skladnosti slik z medsebojno informacijo, so postopki večmodalne poravnave večdimenzionalnih slik neučinkoviti, saj to vodi k veliki računski zahtevnosti. Točkovne mere omogočajo večmodalno merjenje podobnosti poljubno majhnih področij slik (do velikosti posameznih vokslov), zato je ta postopek relativno dober. To vodi k majhni računski zahtevnosti, omogoča izogibanje napakam interpolacije (opisana v naslednjem poglavju), možno pa je tudi uporabiti predhodno znanje o svetlostni odvisnosti slik. Omogoča tudi učinkovito uporabo simetričnega postopka poravnave, ki poveča količino uporabljene informacije o odvisnosti med slikami. S tem pripomore h kakovosti končne poravnave.

Recimo, da imamo problem pacienta, ki je bil večkrat slikan, s pomočjo različnih naprav. Problem nastopi, ker ne moremo pacienta vedno enako slikati, da bodo vse slike enake, primerjanje slik le s pomočjo očesa pa je zelo težko in nenatančno. Da bi rešili takšne probleme, si pomagamo z večmodalno poravnavo slik.

Poznamo tudi več geometrijskih transformacij, npr. iz 2D v 2D, iz 2D v 3D ter iz 3D v 3D.

A. 2D/2D slikovna transformacija

V tem primeru gre za enostaven problem – paralelno projekcijo slike, kjer imamo dve operaciji premikanja (horizontalno in vertikalno). Na spodnji sliki je razvidno, da za 2D transformacijo potrebujemo le rotacijo θ ter parametra t_1 in t_2 .



Slika 5: 2D/2D transformacija

Z naslednjim ukazom v programu *Matlab* naredimo linearno preslikavo (x_1, x_2) v (y_1, y_2) . Točko x_1 množimo z kosinusom kota, odštejemo z produktom sinusa kota in drugo točko x_2 .

$$y_1 = \cos\theta \cdot x_1 - \sin\theta \cdot x_2 + t_1 \quad (1)$$

$$y_2 = \sin\theta \cdot x_1 + \cos\theta \cdot x_2 + t_2$$

Zgornjo enačbo lahko prepišemo v matriko 3x3, pri čemer sta kosinus in sinus prve enačbe vrednosti a_{11} in a_{12} , druge enačbe pa a_{21} in a_{22} , t_1 in t_2 pa a_{13} in a_{23} . Temu postopku pravimo *Homogena transformacija koordinat*.

$$\begin{bmatrix} y_1 \\ y_2 \\ 1 \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ 1 \end{bmatrix} \quad (2)$$

B. 2D/3D slikovna transformacija


Ta transformacija slik je poseben primer obdelave medicinskih slik, ki posebno zanima kirurge. Največ se uporablja v radioterapiji pri načrtovanju in nadzorovanju zdravljenja obolenj, pri operacijah hrbtenice in bokov ter v ortopedski kirurgiji, kjer preverjamo stanje kosti. Poleg tega se uporablja še pri neurointervencijah, virtualni endoskopiji ter nasploh pri slikanju z MRI/CT.

2D/3D transformacija je mogoča z več metodami. Metode, ki temeljijo na intenzivnosti, uporabljajo vrednosti vokslov za transformacijo slik. V večini primerov se uporablja matriko vrednosti vokslov, katero se s postopki maksimizira ali minimizira. Glavne matrike preslikav so naslednje [5]:

- Križna korelacija
- Entropija
- Medsebojna informacija
- Intenziteta vzorčenja

Uporabljajo se tudi metode, ki temeljijo na intenziteti signalov.

Za transformacijo 3D volumnov v rentgenske slike, metode intenzitete signala ustvarijo Digitalno Rekonstrukcijo Rentgenskih slik (DRR). Projekcija iz točk iz 3D v 2D koordinatni sistem se določi tako, da se točke v vsakem prostoru ki ustrezajo določeni anatomske točki medsebojno preslikajo. Dobra uprizoritev je prikazana v naslednji sliki (Slika 5).



Slika 6: Transformacija slike iz 3D v 2D.

Dobljena slika je simulacija rentgenske slike, ki je potrebna za izračun metrike transformacije. Odvisno od metode transformacije, se ta matrika maksimizira oz. minimizira z različnimi numeričnimi tehnikami. Najbolj karakteristična tehnika je normalizirana križna korelacija. Prednost te tehnike je enostavna strojna implementacija, zaradi česar je uporabna v aplikacijah, ki potekajo v realnem času (v živo). Ima pa tudi nekaj slabosti. Glavna negativna plat je, da je zelo odvisna od jakosti signala.

Merjenje entropije izvira iz teorije informacij. Za 2D/3D poravnavo slik deluje na sliki sprememb, katera nastane z odštevanjem DDR-slike od referenčne. Definirati je potrebno primeren faktor skaliranja s , preden nastopi odštevanje slik. Zaradi uporabe histogramov, se za vsak vokal upošteva enaka težnostna porazdelitev. To pripomore k boljši robustnosti v primeru, ko ima majhno število voksov veliko spremembo v intenzivnosti signalov.


Druga pomembna tehnika, ki izvira iz teorije informacij, je tehnika medsebojne informacije (MI – *Mutual Information*). Glede na članek Zitova [2], je ta tehnika, ki vključuje medsebojno informacijo ključna pri transformaciji iz 3D v 3D večmodalnih slik. Penney [3] bolj specifično trdi, da je ta tehnika predvsem uporabna za 3D transformacijo MR/PET in MR/CT slik. Za izračun MI je potreben vezan histogram. Maksimizacija MI je premo sorazmerna z minimizacijo obsega vezanega histograma. V članku [3] je to opisano kot »MI ne prevzame linearne relacije med vrednosti voksla dveh slik, temveč pravi, da je verjetnost najbolj mogočih vrednosti obeh slik maksimizirana v postopku transformacije«. Ta lastnost je zelo uporabna pri transformaciji 3D/3D.

Naslednja metoda, ki temelji na intenziteti signalov je intenziteta vzorčenja [4]. Ta deluje na sliki razlik, ki je opisana v odstavku o entropiji. Po transformaciji slik ostane le še malo

število različnih struktur (npr. rebra) v sliki sprememb. V primeru te metode, vokal pripada strukturi, če ima bistveno različno vrednost intenzitete, glede na njegove sosedje. Sosedji voksla so v radiju r .

IV. INTERPOLACIJA

V primeru *Slike 2* imata sliki A in B svetlost določeno le v točkah, ki jih lahko predstavimo kot mrežasto strukturo voksov. Po opravljenem postopku geometrijske transformacije (ali tudi prej) B v B' se položaj teh točk premakne, kar pomeni, da se sliki ne ujemata več s položajem točk referenčne slike A. V tem primeru lahko s postopki interpolacije ocenimo vrednosti med podanimi točkami slik. Te namreč niso znane, so pa potrebne za izračun podobnosti slik.



Slika 7: Primer dvodimenzionalnih mrež slik po transformaciji. Zamaknjena mreža je iz slike B', poravnana pa iz slike A.


A. Interpolacija bližnjih sosedov (ničtega reda)

Najenostavnejša metoda je interpolacija bližnjih sosedov [6]. Svetlobno vrednost točke, ki ni znana, dodeli vrednost najbližje sosednje točke. Tako se celotnim področjem enega voksla dodeli ista vrednost svetlosti, kar pomeni da s tem ne moremo zagotoviti ločljivosti, ki bi bila manjša od velikosti voksla. To interpolacijo uporabimo, če algoritem zahteva veliko interpolacij, saj je ta najhitrejša.

B. Linearna interpolacija

Linearna interpolacija je interpolacija prvega reda. Odvisno od dimenzij slik, je ta lahko bilinearna (2D) ali trilinearna (3D). Linearna interpolacija deluje tudi kot filtriranje, saj sivinsko vrednost v novi točki določimo kot vteženo povprečje sosednjih, znanih sivinskih vrednosti. Uteži so odvisne od reda interpolacije in od položaja interpolirane točke. Ko so vse uteži enake, je filtriranje najbolj izrazito. To je takrat, ko je interpolirana točka točno v sredini med točkami z znanimi vokslami. Ko se interpolirana točka približuje eni od teh točk, se stopnja filtriranja manjša, ko pa sta točki istoležni filtriranja praktično ni več.

Uteži ω_n v spodnjem primeru predstavljajo ploščino (2D) ali prostornino (3D) področij. S tem pridobimo nove svetlostne vrednosti, ki na originalni sliki niso prisotne.



Slika 8: Predstavitev bilinearna interpolacija.

linearne interpolacije pri uporabi statističnih mer podobnosti, kot so MI, NMI in H ni priporočljiva, saj nove svetlobne vrednosti povzročijo bistvene spremembe lastne verjetnostne porazdelitve svetlostnih nivojev interpolirane slike, poleg tega pa pride tudi do nepredvidljive spremembe vezane verjetnosti porazdelitve slik. Zato je verjetnostna interpolacija boljša rešitev.

C. Verjetnostna interpolacija

Najprimernejša je metoda verjetnostne interpolacije ali PVI (angl. *partial volume interpolation*). Rezultat te interpolacije ni svetlostna vrednost iskane točke oz. slika, interpolirana na tak način, vendar svetlostna vezana verjetnostna porazdelitev slik oz. vezan histogram.

Verjetnostna interpolacija se od linearne loči po tem, da uteži za nek vokal n niso uporabljene za izračun nove svetlostne vrednosti, ki bi prispevala le k vezani verjetnosti enega svetlostnega para (za delež $1/n$). Ta delež se namreč razporedi med več svetlostnimi pari skladno z utežmi.


Seveda, je to metodo mogoče uporabiti le za mere podobnosti, katere temeljijo na določitvi histograma, kot so SDH, MI, NMI, E in EDI. Napake, ki se zgodijo pri PVI niso posledica filtriranja, ampak spremenjenih robnih pogojev slik. Če bi te lahko odstranili, napak interpolacije pri premiku sploh ne bi bilo, napake pa bi se še vedno pojavljale pri deformaciji slik. S PVI pa se doseže veliko izboljšanje pri meri podobnosti E, ki je sicer zelo podvržena napakam interpolacije. V tem primeru dosežemo predvsem manjšo računsko zahtevnost, ne glede na to, da je po rezultatu enaka MI. S tem lahko izboljšamo tudi mero EDI, ki postane primerna predvsem za začetne korake globalnih poravnav.

Še vedno pa bi napake interpolacije nastajale v primeru deformacij slik. Posebno veliko izboljšanje se s PVI doseže pri meri podobnosti E, ki je sicer zelo podvržena napakam interpolacije, v tem primeru pa postane po rezultatu identična MI, vendar pa ohrani manjšo računsko zahtevnost. Podobno se zelo izboljša tudi mera entropije slike razlik (EDI - angl. *entropy of image difference*), ki s tem postane primerna predvsem za začetne korake globalnih poravnav.

D. Lokalni ekstremi

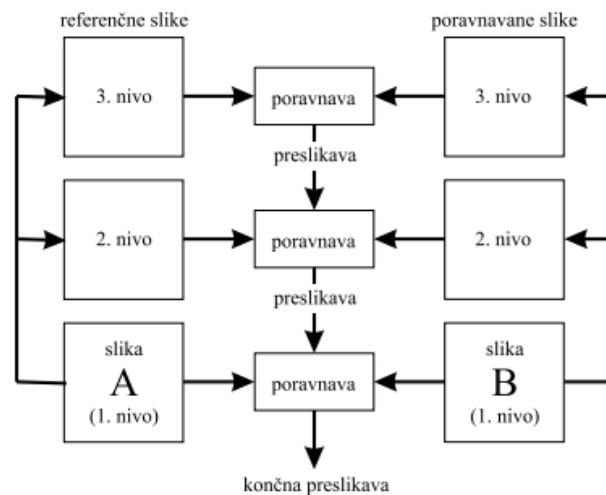
Lokalni ekstremi funkcije podobnosti so pogosto lahko vzrok za napačne rezultate in otežujejo proces poravnave slik. Lokalni ekstremi se lahko pojavljajo zaradi medsebojnih

podobnosti različnih področij iste slike in vpliva interpolacije, ki se kaže kot periodična funkcija s periodo enega voksla in je superponirana funkciji podobnosti. Lokalne ekstreme, ki so posledica prvega vzroka, je mogoče zmanjšati in celo odpraviti s postopno več-nivojsko poravnavo. To naredimo tako, da s skalirnimi ali piramidnimi postopki zmanjšamo informacijo slik. S tem iz prvotnih slik odstranimo glavni vir lokalnih ekstremov – podrobnosti. Tako postane funkcija podobnosti bolj gladka in vsebuje vse manj lokalnih ekstremov. Istočasno postaja manj izrazit tudi globalni ekstrem, s čimer se zmanjšuje natančnost poravnave. Izogibanje večini lokalnih ekstremov brez zmanjšanja natančnosti poravnave torej poteka s postopno poravnavo, ki v začetnih iteracijah temelji na grobih slikah z malo detajli, nadaljuje na vse bolj informacijsko polnih slikah in konča z dejansko poravnavo originalnih slik.



Slika 9: Odpravljanje lokalnih ekstremov s piramidnim podvzorčenjem in linearnim skaliranjem.

Več-nivojska poravnava se začne tam, kjer slike vsebujejo najmanj podrobnosti in ima funkcija podobnosti najmanj lokalnih ekstremov – na najvišjem nivoju. Konča se na najnižjem (prvem) nivoju, s poravnavo originalnih slik (Slika 10).



Slika 10: Več-nivojska poravnava.

Predhodno filtriranje interpolirane slike je najenostavnejši način, da napake interpolacije zmanjšamo. Celotno filtriranje, kar zajema predhodno filtriranje in dejansko interpolacijo je

zato bolj enakomerno in vpliv interpolacije je zato manjši. S filtriranjem pa se zmanjša tudi točnost dejanske poravnave, saj povzroči zmanjšanje izrazitosti globalnega ekstrema. *Drhtenje*, kot druga opcija, lahko pripomore k odpravljanju napak interpolacije. Ta deluje tako, da premakne vsako interpolirano točko za neko naključno razdaljo od njene prave lege. Velikost premika mora biti sorazmerna porazdelitvi na področju od nič do polovice velikosti slikovnega elementa. Povprečna vrednost napak interpolacije postane s tem statistično neodvisna od uporabljene transformacije poravnane slike. Ta postopek ne povzroči nobene sistematske napake, saj je pričakovana vrednost naključnih premikov enaka nič.

V. INTERPOLACIJA V PRIMERU

Primerjati želimo različne metode interpolacije. Glavni problem interpolacije, ki ga pričakujemo, so napake interpolacije (ang. *interpolation artifacts*). Preizkusiti želimo naslednje dve postopke interpolacije:

- Linearna interpolacija svetlosti
- Interpolacija delnih volumnov

Oba postopka sta implementirana v programu Matlab,

A. Linearna interpolacija svetlosti v praksi

Z linearno interpolacijo svetlosti geometrijske razlike med slikama odpravimo s prevzorčenjem ene slike na mrežo vokslov druge slike, pri čemer uporabimo (tri)linearno interpolacijo. Celoten proces interpolacije in iskanja najboljšega ujemanja slik je sestavljen iz več faz:

- pridobitev BrainWeb slik (A, B) iz spletne strani http://brainweb.bic.mni.mcgill.ca/brainweb/selection_normal.html
- transformacija ene slike (B)
- interpolacija
- iskanje najbolj optimalne transformacije za poravnavo interpolirane slike (B1) s prvotno sliko (A) z uporabo NLOPT

Na zgoraj navedeni spletni strani je mogoče pridobiti obdelane medicinske slike z anatomske modelom možganov, s katerimi se lahko poslužujemo pri testiranju oz. prikazu metode interpolacije. Iz baze podatkov lahko pridobimo slike treh različnih modalnosti, pet različnih debelin, šest različnih vrednosti šuma na sliki ter tri vrednosti, ki nam povejo, za koliko sta si sliki različni. V našem primeru želimo pridobiti slike različnih modalnosti, zato uporabimo prvo opcijo T1 ter T2, debelino 1 milimetra (saj bodo tako izračuni lažji in hitrejši), 3% šum ter 0% razliko, saj želimo, da sta si sliki čim bolj enaki. Slike nato izvozimo »surove«, v raw-byte formatu, ter najbolje brez kompresije, da ne bi prišlo do napak. Omeniti velja, da sta sliki velikosti 181 x 217 x 181 vokslov.

S tem, ko smo pridobili slike, na katerih bomo izvajali operacije, je potrebno konfigurirati razvojno okolje Matlab. Ker bomo imeli opravka s slikami, bomo uporabljali dodatek »Image processing toolbox«. Slike v Matlabu preberemo s klicem funkcije *read*, ki je zapisana v datoteki *Read.m* in ju

definiramo kot globalni spremenljivki, saj ju bomo uporabljali tudi znotraj ostalih funkcij.

Transformacijo izvedemo nad sliko B (T2). Definiramo jo z dvema vektorjema, ki predstavljata premik ter obrat. V našem primeru recimo, da želimo le izvesti premik za 2 voksla po vseh treh oseh (x, y, z).

Ker v tem primeru gre za linearno interpolacijo svetlosti, uporabimo ukaz *interp3*, kjer za parametre podamo koordinate poravnane slike B in poravnane slike B1.

Z uporabo NLOPT knjižnice pridobimo najbolj optimalne transformacije za poravnavo interpolirane slike B1 s prvotno sliko A. NLOPT je potrebno konfigurirati s optimalno funkcijo tako, da iz vezanega histograma slik pridobi tisto vrednost medsebojne informacije, ki je največja. To naredimo s klicem funkcije *OptFunkcija* in *MedsebojnaInformacija*. Za izračun MI iz vezanega histograma pa potrebujemo še izračun vezane entropije, pri čemer si pomagamo s funkcijo *Entropija*. Z njo dejansko izmerimo razpršenost vezanega histograma. Spodaj je naveden primer izračuna medsebojne informacije in vezane entropije.

```
global A;
I=[A(:),TB(:)];
jointH = hist3(I,{0:255, 0:255});
```

```
e0=Entropija(jointH);
```

```
eA0=entpy( sum(jointH,1) );
eB0=entpy( sum(jointH,2) );
```

```
MI=eA0+eB0-e0;
```

```
function ent = Entropija(hist)
p=hist(:)/sum(hist(:));
plogp=p.*log2(p);
plogp(p==0)=0;
ent= -sum(plogp);
end
```

Celoten klic NLOPT funkcije želimo časovno izmeriti, saj nas zanima čas iskanja maksimalne vrednosti medsebojne informacije. Z ukazom *tic* zaženemo uro, z ukazom *toc* pa jo zaustavimo.

Na koncu, za lažjo predstavitev poteka dogajanja, lahko sproti prikazujemo korake iskanja maksimalne MI. Poleg izpisa NLOPT funkcije je še pametno prikazati premike, obrate in porabljen čas za izvedbo. Za lažjo predstavilo si te vrednosti shranimo v vektor velikosti 7.

B. Interpolacija delnih volumnov

Tako, kot v implementaciji linearne interpolacije svetlosti, lahko tudi tu uporabimo del že spisane kode. V prejšnjem primeru smo imeli matriko s koordinatami (*xo*, *yo*, *zo*), pri čemer vsak element te matrike predstavlja koordinate posameznega voksla na transformirani sliki. V tem primeru želimo najti najbližje voksle na drugi, fiksni oz. referenčni sliki.

Fiksna slika ima kvadratno mrežo in se v x , y , z smeri z vokslu spreminja v stalnem koraku, ki je enak velikosti voksla. Vse skupaj je torej od izhodišča koordinatnega sistema zamaknjeno za izhodiščni premik (v kodi poimenovan *origin*) – matrika s koordinatami (x_i , y_i , z_i). Glede na navedene podatke je ob upoštevanju stalne kvadratne mreže za vsako koordinato mogoče neposredno izračunati kateri so njeni najbližji vokslu, po vsaki izmed smeri. Ker imamo 3D slike, je število sosednjih vokslu 8, med katerimi nato interpoliramo. V primeru linearne interpolacije svetlosti se iz vokslu neposredno določi vrednost interpolirane svetlosti fiksne slike, nato pa se par svetlosti (svetlost voksla na interpolirani sliki in interpolirana vrednost na fiksni sliki) uporabi pri izračunu vezanega histograma. Pri PVI je le ta korak različen, saj se ne izračuna interpolirana vrednost fiksne slike, pač pa se v deležih uteži linearne interpolacije upošteva kar vseh 8 svetlostnih parov, pri čemer so svetlostni pari sestavljeni iz svetlosti voksla na transformirani sliki ter svetlosti osmih najbližjih sosedov fiksne slike. Torej, kot rezultat ne dobimo interpolirane slike, temveč kar vezan histogram. Tega lahko kasneje uporabimo za izračun večmodalne podobnosti, kot je npr. medsebojna informacija (MI).

Izračun najbližjih sosedov je razmeroma enostaven. Če pogledamo izračun posamezne koordinate slikovnega elementa v 1D, je sledeč:

$$x = i * velikost_voksla - origin \quad (4)$$

Pri zgornjem izračunu i predstavlja *indeks voksla*, x pa koordinato voksla, odmaknjena od izhodišča za vrednost *origin*. V tem primeru formulo obrnemo, in iz danega $x = x_0$ izračunamo indeks i . Najbližje sosedne dobimo tako, da ta indeks zaokrožimo navzgor in navzdol. Z vsemi kombinacijami tako dobimo 8 sosednjih vokslu.

```
s1 = (xo + origin(2)) / (vsize(2));
s2 = (yo + origin(1)) / (vsize(1));
s3 = (zo + origin(3)) / (vsize(3));
```

```
ix = floor(s1);
iy = floor(s2);
iz = floor(s3);
jx = ix+1;
jy = iy+1;
jz = iz+1;
```


Ko preračunamo posamezen voksel transformirane slike z zgornjo enačbo ugotovimo indekse okoliških vokslu fiksne slike. Njihove uteži določimo z linearno interpolacijo, ki temelji na razliki prave vrednosti od zgoraj navedenih celoštevilskih zaokrožitev. Ta govori, kako blizu je posamezni transformirani voksel vsakemu od sosedov. Npr. v primeru 1D, če ugotovimo, da je $ix = 5,4$, vemo, da sta sosednja voksla netransformirane slike z indeksi 5 in 6. Poleg tega vemo, da je relativna razdalja do voksla 5 enaka $0,4$, do voksla 6 pa $0,6$. Pri linearni interpolaciji svetlosti bi svetlost netransformirane slike na lokaciji transformiranega voksla v tem primeru določili kot:

$$i_R = i_5 * 0.6 + i_6 * 0.4 \quad (3)$$

Pri tem so i intenzitete (svetlosti) z utežjo $0,6$ in (i_T , i_6) z utežjo $0,4$, i_T pa predstavlja svetlost voksla transformirane slike.

VI. REZULTATI

Rezultati, dobljeni z zgoraj opisanimi metodama so prikazani v spodnjem grafu, izrisanem v programu Microsoft Excel. Dobljene rezultate smo zapisali v stolpce ter iz njih narisali graf. V primeru linearne interpolacije, smo za primerjalni primer upoštevali vrednosti, dobljene brez optimizacije – NLOPT-a. Rezultati so v spodnjem grafu, kjer so na x-osi zapisani premiki od -10 do 10 enot po x-osi s korakom 0.1, na y-osi pa so prikazane dejanske vrednosti dobljene medsebojne informacije (MI) od 0 do 1.




Slika 11: Primerjava rezultatov linearne interpolacije ter interpolacije delnih volumnov


Iz zgornjega grafa je lepo razvidno, da se rezultati rahlo razlikujejo, saj pri interpolaciji svetlosti upoštevamo področje celotne slike, pri PVI interpolaciji pa le prekrivajoč del slik. Pomembno je, da imata obe interpolaciji enake rezultate pri premiku za 0 stopinj. Poleg tega je tudi opaziti, da je pri linearni interpolaciji prišlo do izrazitejših napak, medtem ko so bile pri PVI te napake minimalne. Napake interpolacije so pereč problem, saj so vzrok za nastajanje lokalnih ekstremov funkcije podobnosti, ki otežijo pravilno poravnavo slik.

Kot opisano v poglavju o verjetnosti porazdelitvi, bi se lahko teh lokalnih ekstremov znebili tako, da bi sliki skalirali, ter ju nato primerjali. S tem bi izgubili veliko majhnih detajlov na sliki, a bi pridobili na natančnosti rezultatov poravnave primerjanih slik. A zadostovala je že sama implementacija interpolacije delnih volumnov, da smo se napak skorajda znebili.

Zaradi lažjega razumevanja, smo pri risanju histogramov uporabili logaritem vrednosti. Oba dobljena histograma pri premiku 0 sta predstavljena spodaj.



Slika 12: Histogram, dobljen z linearno interpolacijo slik.



Slika 13: Histogram, dobljen z interpolacijo delnih volumnov.

Zanimivo je tudi preveriti, koliko časa potrebujemo za izračun medsebojne informacije. Oba postopka namreč trajata kar nekaj časa. Pognali smo testni primer za posamezen obrat slike, ter dobili sledeče rezultate. Razvidno je, da za samo eno poravnavo z metodo interpolacije porabimo veliko časa, kar nam precej zmanjša možnosti, da bi se lahko ti postopki, implementirani v programu Matlab uporabljali tudi v praksi.

Vrsta interpolacije	Čas (v sekundah)
Linearna interpolacija	212
PVI	57

POVZETEK

V članku smo obravnavali poravnavo medicinskih slik, bolj specifično pa smo opisali večmodalno poravnavo. Implementacijski del je zavzemal področje interpolacije, in sicer linearno interpolacijo svetlosti ter interpolacijo delnih volumnov. Rezultati so pokazali, da smo z interpoalcijo delnih volumnov odpravili nekatere napake (lokalne ekstreme), ki so se zgodili pri linearni interpolaciji, vendar smo pri tem porabili ogromno časa. Na podlagi tega lahko sklepamo, da je obdelava medicinskih slik v programu Matlab precej časovno potratna in razmeroma neuporabna za potrebe analiziranja slik v praksi. Za delo v prihodnje bi bilo zanimivo narediti linearno interpolacijo nad skaliranimi slikami ter ugotovljati, če še vedno prihaja do lokalnih ekstremov in se jih s to metodo poskusiti znebiti. Poleg tega bi bilo še vredno implementirati novo metodo interpolacije, in sicer interpolacijo točkovnih podobnosti, ki je mogoča ob uporabi točkovnih mer ter rezultate primerjati z rezultati, dobljenimi pri interpolaciji delnih volumnov.

LITERATURA

- [1] P. Rogelj, S. Kovačič, "Poravnava medicinskih slik," Zbornik prispevkov strokovne konference ROSUS 2006 Računalniška obdelava slik in njena uporaba v Sloveniji 2006, Maribor, 23. marec 2006.
- [2] J. B. Zitova, J. Flusser, "Image registration methods: a survey", Image and Vision Computing, 21 (2003), pp 977-1000.
- [3] G. P. Penney, J. Weese, J. A. Little, P. Desmedt, D. L. G. Hill, and D.J. Hawkes, "A comparison of similarity measures for use in 2-D-3-D medical image registration," IEEE Trans. Med. Imag., vol. 17, no. 4, pp.586-595, Apr. 1998K. Elissa.
- [4] J. Weese, G. P. Penney, P. Desmedt, T. M. Buzug, D. L. G. Hill, and D. J. Hawkes, "Voxel-based 2-D/3-D registration of fluoroscopy images and CT scans for image-guided surgery," IEEE Trans. Inf. Technol.
- [5] P. D. Kotsas, T. Dodd, A Review of Methods for 2D/3D Registration., World Academy of Science, Engineering and Technology 59 2011.
- [6] F. Maes, A. Collignon, D. Vandermeulen, G. MArchal, and P. Suetens. Multimodality image registration by maximization of mutual information. IEEE Transactions on Medical Imaging, 16(2):187-198, April 1997.
- [7] P. Rogelj, S. Kovačič, "Večmodalna netoga poravnava medicinskih slik," Elektrotehniški vestnik 74(5): 309-314, 2007
- [8] P. Rogelj, "Elastična poravnava medicinskih slik različnih modalnosti," Magistrsko delo, Univerza v Ljubljani, Fakulteta za elektrotehniko, Ljubljana, April 2001
- [9] J. L. Semmlow, "Biosignal and Biomedical Image processing: MATLAB based Applications," Signal processing and communications, Taylor & Francis INC. 1. edition, January 2004
- [10] T. Maintz, "Digital and Medical Image Processing", University of Utrecht, 2003, <http://www.cs.uu.nl/docs/vakken/imgp/>
- [11] P. J. Kostelec, S. Periaswamy, "Image registration for MRI," Modern signal processing, MSRI Publications, Volume 46, 2003
- [12] F. Maes, D. Vandermuelen, P. Suetens, "Medial Image Registration Using Mutual Informantion," Invited paper, Proceedings of the IEEE, VOL 91, NO. 10, October 2003
- [13] D. Škerl, S. Kovačič, "Vrednotenje mer podobnosti za poravnavo medicinskih slik," Magistrsko delo, Univerza v Ljubljani, Fakulteta za elektrotehniko, Junij 2004
- [14] Peter Rogelj, Stanislav Kovačič. Similarity Measures for Non-RigidRegistration. V: The Proceedings of the SPIE Symposium on Medical Imaging 2001, San Diego, California, USA, February 17-23, 2001.